

Benchmark de de metodos de detecção de deepfake aplicados a um dataset espezifico

INTRODUÇÃO

Deepfake é uma técnica de síntese de mídia que utiliza redes neurais profundas. Desde que se tornou popular em 2017, com um modelo de troca de rostos (face swap) apresentado no Reddit [Deepfakes, 2017], a tecnologia avançou consideravelmente, permitindo agora reencenação facial, alteração de expressões e até criação completa de vídeos reencenados [Suwajanakorn et al., 2017]. No cinema, deepfakes foram empregados para rejuvenescer atores em filmes como Gemini Man [Murphy et al., 2023]. Por outro lado, na educação, tutores virtuais personalizados foram desenvolvidos com IA para atender a diversos perfis de estudantes [Roe et al., 2024]. No segmento de varejo, marcas já utilizam a tecnologia para permitir a experimentação virtual de roupas e acessórios [Caporusso, 2021].

No entanto, o uso inadequado de deepfakes tem aumentado de forma preocupante. Em fevereiro de 2024, uma multinacional de Hong Kong perdeu 25 milhões de dólares devido a um golpe que usou deepfakes durante uma videoconferência [Melappalayam, 2024]. Em abril do mesmo ano, um golpista fingindo ser Elon Musk conseguiu enganar uma vítima, o que levou ao desvio de uma quantia equivalente a 50 mil dólares [Sharma, 2024]. Esses acontecimentos evidenciam o progresso das técnicas de manipulação e a necessidade urgente de criar sistemas de detecção sólidos e confiáveis.

Deepfake está entre os cinco principais tipos de fraude de identidade em 2023. De acordo com a DeepMedia, uma startup que desenvolve ferramentas para identificar mídias falsas, o número de deepfakes de vídeo de todos os tipos triplicou e o número de deepfakes de voz aumentou oito vezes em 2023 em comparação com o mesmo período de 2022. Eles estimaram que cerca de 500.000 deepfakes de vídeo e áudio serão carregados em sites de mídia social em todo o mundo até o final de 2023 (Ulmer e Tong, 2023). Listamos algumas tendências importantes na evolução das fraudes com deepfake nos últimos 5 anos na Tabela.

Tabela : evolução do uso de deepfakes nos ultimos 5 anos partir de 2019.

Ano	Eventos chaves e tendências
2019	Surgimento e proliferação - Introdução da exploração da tecnologia deepfake para atividades fraudulentas - Capacidades limitadas de conscientização e detecção
2020	Acessibilidade e uso generalizado - Maior acessibilidade a ferramentas de criação de deepfakes fáceis de usar - Melhoria nas abordagens de detecção, mas os deepfakes estão se tornando mais sofisticados
2021	Avanços tecnológicos - Golpe com deepfake ganha atenção do público em geral - Variações regionais na frequência de fraudes com deepfake
2022	Realismo e sofisticação - Aumento significativo de incidentes de fraude com deepfakes em diversos setores - Os criminosos adotam técnicas mais avançadas, dificultando a detecção - Primeiro passo em direção ao trabalho em equipe interdisciplinar para combater a fraude com deepfakes
2023	Presente: duelo tecnológico entre criminosos e defensores - Há uma corrida armamentista tecnológica contínua entre fraudadores e medidas de segurança - A interminável corrida armamentista entre cibercriminosos e sistemas de defesa - Os riscos dos deepfakes são agora mais amplamente reconhecidos em todo o mundo - Houve um aumento de dez vezes na detecção mundial de deepfakes em todos os setores de 2022 a 2023


Fonte: Adaptado de Tyagi e Yadav (2024)

As mídias deepfake podem ser de diferentes tipos, dependendo do conteúdo manipulado. Essas manipulações incluem modificações visuais, de áudio e textuais (Tolosana et al.2020). A Figura apresenta os tipos de conteúdo de deepfake. Entre os visuais, textuais e de áudio, os deepfakes visuais são os mais comuns. Eles

incluem principalmente imagens e vídeos falsos. Essas imagens e vídeos falsos são usados em plataformas de mídias sociais para espalhar informações falsas sobre eventos que nunca aconteceram (Zhou e Zafarani 2020).

A “troca de rostos”, que consiste em substituir o rosto do alvo pela imagem original, é um método comum para criar imagens deepfake. Por outro lado, vídeos deepfake podem ser criados por meio de três técnicas: sincronização labial, síntese facial e manipulação de atributos (Nguyen et al., 2019b; Masood et al., 2023).

O deepfake baseado em texto é o segundo tipo. Esses deepfakes textuais são predominantemente utilizados nas redes sociais para criar comentários e avaliações fraudulentos em plataformas de e-commerce. O deepfake de áudio é o terceiro tipo. Esses deepfakes utilizam inteligência artificial para gerar uma fala humana sintética e convincente. É possível criar esses deepfakes por meio de técnicas de conversão de texto em fala ou de troca de voz.



fonte : adaptado — (KAUR et al., 2024)

Figura : Classificação hierárquica do conteúdo deepfake disponível em plataformas de mídia social. A imagem também mostra os métodos usados para criar deepfakes visuais e de áudio. Imagens e vídeos deepfake são frequentemente usados em plataformas de mídia social.

Deepfakes apresentam riscos, como roubo de identidade, fraude informática, chantagem, manipulação de voz ou de imagem durante a autenticação e a criação de provas falsas (Rao et al., 2021). Segundo o Jornal (O Liberal, 2025¹), houve um

¹ <https://www.oliberal.com/policia/em-nove-meses-crimes-com-ia-sobem-185-no-para-1.1040402>

expresso aumento dos crimes envolvendo Inteligência artificial no Pará: “O número de crimes que utilizaram Inteligência Artificial subiu 185% no Pará. De janeiro a setembro de 2024, a Secretaria de Segurança Pública e Defesa Social (Segup) contabilizou 41 casos dessa natureza, enquanto em 2025, no mesmo período, foram 117. ”

Imagens manipuladas são concebidas para uso em plataformas de redes sociais, onde conspirações, rumores e desinformação se espalham rapidamente, pois os usuários tendem a seguir o que está em alta (Masood et al., 2023). Os recentes avanços em deepfakes com inteligência artificial amplificaram ainda mais o problema (Liu et al., 2021b). A maioria dos rostos gerados por GAN nem sequer existe no mundo real. Além disso, a GAN pode fazer alterações faciais realistas em um vídeo, como troca de identidade (Rao et al., 2021). Esse tipo de informação falsa pode ser facilmente transmitido para milhões de pessoas na internet por meio do fácil acesso à tecnologia (Westerlund, 2019).

OBJETO

Fazer um benchmark para avaliação de métodos de detecção de deepfake para um dataset específico.

Objetivos específicos

Mensurar o desempenho dos modelos em um hardware limitado
implementar os modelos em contexto específico
avaliar os modelos de acordo com métricas de eficiência e custo.

Trabalhos Relacionados

A criação e detecção de deepfakes são novas áreas de estudo em visão computacional. Diversos artigos de revisão sobre detecção de deepfakes foram publicados no passado. Pelo menos 90% dessas revisões se concentram em deepfakes de imagens ou de vídeo. O restante das revisões explorou deepfakes relacionados a áudio ou a uma combinação de áudio, vídeo e outros formatos de mídia (Stroebel et al. 2023). Por exemplo, Tolosana et al. (2020) abordam métodos de alteração de imagens faciais, incluindo deepfakes e métodos de detecção. No entanto, esta revisão considerou apenas imagens falsas.

Mirsky e Lee (2021) se concentram em abordagens de reencenação para geração de deepfakes e fornecem diagramas de arquitetura de modelo para cada rede neural profunda DNN usada para métodos de geração de deepfakes. A revisão carece de discussão sobre os desafios técnicos associados aos sistemas de geração e detecção.

Verdoliva (2020) se concentra na verificação da integridade da mídia visual ou na detecção de imagens e vídeos manipulados. Deepfakes criados por aprendizado profundo são apresentados juntamente com novas maneiras forenses baseadas em dados para combatê-los. Eles categorizam os métodos de detecção em abordagens tradicionais e métodos baseados em aprendizado profundo. A análise também mostra os problemas com os métodos forenses atuais e os desafios e oportunidades futuros.

Nguyen et al. (2022) forneceram uma visão geral completa das estratégias de deepfake e incentivaram o desenvolvimento de abordagens mais confiáveis para combater os desafios dos deepfakes.

Masood et al. (2023) analisa ferramentas de geração de deepfake e técnicas baseadas em aprendizado de máquina (ML) para detectar manipulações de áudio e vídeo. Os autores discutem os conjuntos de dados disponíveis e a precisão como os critérios mais importantes para avaliar as estratégias de detecção de deepfake.

Xu et al. (2022) avalia pesquisas sobre geração, detecção e evasão de deepfakes de métodos de detecção. Eles também ilustram o campo de batalha entre os dois lados, incluindo os adversários (criações de DeepFake) e os defensores (detecção de DeepFake). Esta é uma pesquisa extensa com uma

análise de mais de 300 referências; apesar disso, eles não abordaram a questão da complexidade computacional dos métodos de detecção.

Patil et al. (2023) destacaram a importância dos classificadores biológicos na detecção de deepfakes. Eles discutiram como esses procedimentos podem dificultar a identificação de características faciais. Assim, esses algoritmos podem identificar erroneamente vídeos deepfake como falsos.

Rana et al. (2022) examinaram os métodos de detecção de deepfake, categorizando-os em quatro grupos distintos: abordagens baseadas em aprendizado profundo, métodos tradicionais de aprendizado de máquina, técnicas estatísticas e técnicas baseadas em blockchain.

Yu et al. (2021) revisaram minuciosamente a literatura sobre detecção de vídeos deepfake. Eles abordaram a geração de deepfakes, métodos para detectá-los e benchmarks para avaliar o desempenho dos modelos de detecção. A pesquisa indica que as abordagens de detecção atuais são insuficientes para cenários do mundo real. O levantamento destaca a necessidade de métodos de detecção que sejam eficientes, adaptáveis e resistentes às técnicas de manipulação de deepfakes. O estudo concluiu que os métodos de detecção atuais são inadequados para uso em tempo real e devem se concentrar na eficiência de tempo, generalização e confiabilidade.

Gambin et al. (2024) enfatizam que a colaboração entre pesquisadores, governos, e organizações empresariais é essencial para criar e implementar estratégias bem-sucedidas de detecção e prevenção de deepfakes. Eles discutiram o potencial dos registros distribuídos e da tecnologia blockchain para aprimorar as medidas de segurança cibernética contra deepfakes.

Um levantamento recente de Gong e Li (2024) classificou os métodos de detecção de deepfakes como detecção convencional baseada em CNN, CNN com detecção semi-supervisionada, detecção baseada em transformers e detecção de sinais biológicos. O levantamento compara conjuntos de dados e metodologias de detecção de deepfakes, destacando seus prós e contras. Os autores discutem os desafios de obter resultados precisos em diferentes conjuntos de dados e sugerem direções futuras para aumentar a confiabilidade da detecção.

Revisão Literaria

Redes Adversárias Generativas (GANs)

As GANs, compostas por um gerador e um discriminador treinados de forma adversarial (veja a Figura 2), tornaram-se o principal mecanismo para a geração de faces realistas [Goodfellow et al., 2014]. Abordagens como FaceShifter [Li et al., 2019] e SimSwap [Chen et al., 2020] propõem modelos independentes de identidade que integram características faciais da origem na imagem-alvo, com maior robustez a oclusões. Posteriormente, arquiteturas baseadas no StyleGAN [Karras et al., 2021] viabilizaram a geração de imagens em alta resolução [Wang et al., 2024a]. Apesar da alta qualidade dos resultados, o treinamento de GANs exige cuidados com a estabilidade e a escolha de hiperparâmetros, além de etapas adicionais de pós-processamento para a remoção de artefatos [Kim et al., 2025].




Figura 2. Esquema de treinamento de uma GAN para geração de faces. O gerador cria imagens sintéticas enquanto o discriminador tenta distingui-las das reais, em um processo adversarial que leva à geração de faces mais realistas.

Segundo (Wang & Yu, 2023) o desenvolvimento das GANs gerou uma variedade de variantes para melhorar a qualidade da geração e a estabilidade do treinamento. A DCGAN introduz uma estrutura convolucional para melhorar a nitidez da imagem, que é adequada para a geração de imagens estáticas; a WGAN introduz a distância de Wasserstein em vez da função de perda original para aliviar

o problema de treinamento instável e desaparecimento do gradiente; a CGAN introduz rótulos condicionais no gerador e no discriminador para tornar o conteúdo gerado controlável; a StyleGAN introduz incorporação de estilo multiescala para controlar os detalhes da imagem; a VideoGAN e a MoCoGAN são estendidas ao domínio de vídeo e introduzem modelagem temporal para controlar os detalhes da imagem (Arjovsky & Bottou, 2017) .

fonte : (Arjovsky & Bottou, 2017)




Figura . Cronologia das GANs com arquiteturas variantes apresentadas neste artigo. A complexidade no fluxo azul refere-se ao tamanho da arquitetura e ao custo computacional, como o tamanho do lote. Os mecanismos referem-se ao número de tipos de operações (por exemplo, convolução, deconvolução, autoatenção) usadas na arquitetura (por exemplo, a FCGAN usa camadas totalmente conectadas tanto para o discriminador quanto para o gerador. Nesse caso, o valor para mecanismos é 1).

fonte : 4 Generative Adversarial Networks in Computer Vision

Autoencoders

(Representation Learning: A Review and New Perspectives)

Na estrutura do autoencoder (LeCun, 1987; Bourlard e Kamp, 1988; Hinton e Zemel, 1994), começa-se definindo explicitamente uma função de extração de características em uma forma fechada parametrizada específica. Essa função, que denotaremos por f_θ , é chamada de codificador e permitirá o cálculo direto e eficiente de um vetor de características $h = f_\theta(x)$ a partir de uma entrada x . Para cada exemplo $x(t)$ de um conjunto de dados $\{x(1), \dots, x(T)\}$, definimos

$$h(t) = f_\theta(x^t)$$

onde $h(t)$ é o vetor de características, representação ou código calculado a partir de $x(t)$. Outra função parametrizada em forma fechada, g_θ , chamada de decodificador, mapeia do espaço de características de volta para o espaço de entrada, produzindo uma reconstrução $r = g_\theta(h)$.

Para Bengio et al. (2013) enquanto modelos probabilísticos são definidos a partir de uma função de probabilidade explícita e são treinados para maximizar (frequentemente de forma aproximada) a verossimilhança dos dados (ou uma aproximação), os autoencoders são parametrizados por meio de seu codificador e decodificador e são treinados usando um princípio de treinamento diferente. O conjunto de parâmetros θ do codificador e decodificador é aprendido simultaneamente na tarefa de reconstruir da melhor forma possível a entrada original, ou seja, tentando incorrer no menor erro de reconstrução possível $L(x, r)$ – uma medida da discrepância entre x e sua reconstrução r – em exemplos de treinamento. Uma boa generalização significa baixo erro de reconstrução em exemplos de teste, enquanto apresenta alto erro de reconstrução para a maioria das outras configurações de x . Para capturar a estrutura da distribuição geradora de dados, é, portanto, importante que algo no critério de treinamento ou na parametrização impeça o autoencoder de aprender a função identidade, que tem erro de reconstrução zero em todos os lugares. Isso é alcançado por meio de vários métodos nas diferentes formas de autoencoders, conforme descrito abaixo em mais detalhes, e chamamos esses de autoencoders regularizados. Uma forma particular de regularização consiste em restringir o código a ter uma dimensão baixa, e é isso que o autoencoder clássico ou PCA fazem.




figura : Basic architecture of an autoencoder is shown in Fig. 1

fonte : <http://ufldl.stanford.edu/tutorial/unsupervised/Autoencoders/>

A figura acima mostra como o Autoencodar insere a entrada ($x_1 \dots x_6$) passa por uma camada intermediária menor (gargalo com 5 neurônios) que força a rede a extrair apenas as características essenciais, e depois tenta reconstruir a saída original ($\hat{x}_1 \dots \hat{x}_6$). O objetivo é minimizar a diferença entre entrada e saída, fazendo a rede aprender automaticamente uma representação compacta e eficiente dos dados, útil para redução de dimensionalidade, remoção de ruído e detecção de anomalias.

Paradigmas de detecção

A detecção de deepfakes é tipicamente considerada um problema de classificação binária, no qual classificadores são usados para distinguir entre vídeos confiáveis e fraudulentos (Singh et al., 2021). Essa técnica requer uma grande biblioteca de vídeos reais e falsos para treinar modelos de classificação. O número de vídeos fraudulentos está crescendo, embora ainda seja insuficiente para fornecer um padrão para validar vários métodos de detecção (Q. Liu & Celebi, 2021).

Diversos estudos anteriores sobre a detecção de imagens ou vídeos deepfake focaram-se em técnicas de aprendizado profundo (DL), que podem ser divididas em dois métodos de detecção: métodos baseados em Redes Neurais Convencionais (CNN) e métodos baseados em Redes Neurais Convencionais Regionais (RCNN) (X. Zhou et al., 2020).

CNNs

(<http://ufldl.stanford.edu/tutorial/supervised/ConvolutionalNeuralNetwork/>)

Uma Rede Neural Convolutiva (CNN) é composta por uma ou mais camadas convolucionais (frequentemente com uma etapa de subamostragem) seguidas por uma ou mais camadas totalmente conectadas, como em uma rede neural multicamadas padrão. A arquitetura de uma CNN é projetada para aproveitar a estrutura 2D de uma imagem de entrada (ou outra entrada 2D, como um sinal de voz). Isso é alcançado com conexões locais e pesos vinculados, seguidos por alguma forma de pooling, o que resulta em características invariantes à translação. Outro benefício das CNNs é que elas são mais fáceis de treinar e possuem muito menos parâmetros do que redes totalmente conectadas com o mesmo número de unidades ocultas. Neste artigo, discutiremos a arquitetura de uma CNN e o algoritmo de retropropagação para calcular o gradiente em relação aos parâmetros do modelo, a fim de usar a otimização baseada em gradiente. Consulte os respectivos tutoriais sobre convolução e pooling para obter mais detalhes sobre essas operações específicas (Stanford University, 2015).




Fig 1: First layer of a convolutional neural network with pooling. Units of the same color have tied weights and units of different color represent different filter maps.

As CNNs (Redes Neurais Convolucionais) são fundamentais para a detecção de deepfakes porque possuem capacidades inerentes de extrair características visuais de baixo nível significativas, detectando variações sutis em nível de pixel através de kernels convolucionais de pequena dimensão. (Enhancing practicality and efficiency of deepfake detection) (Stanford University, 2015).

As técnicas baseadas em CNN extraem imagens faciais de quadros de vídeo e as alimentam na CNN para treinamento e previsão, a fim de obter um resultado em nível de imagem. Assim, em vídeos deepfake, esses algoritmos empregam apenas informações espaciais de um único quadro. As técnicas baseadas em RCNN, por outro lado, requerem uma série de quadros de vídeo para treinamento, a fim de produzir um resultado em nível de vídeo. Essa abordagem, conhecida como RCNN, combina CNN e Redes Neurais Recorrentes (RNN) (Tariq et al., 2021). Como resultado, as técnicas baseadas em RCNN podem utilizar plenamente as informações espaciais e temporais em filmes deepfake (Chung et al., 2015). Além disso, vários métodos de detecção de deepfakes são baseados em métodos padrão de aprendizado de máquina, incluindo a utilização de uma máquina de vetores de suporte (SVM) como classificador e a extração de características manuais, incluindo sinais biológicos, como classificador (Yazdinejad et al., 2020).


Frequency-aware

Os algoritmos de manipulação facial de última geração, como DeepFake ,FaceSwap , Face2Face e NeuralTextures , conseguiram ocultar os artefatos de falsificação, tornando extremamente difícil a descoberta das falhas dessas falsificações refinadas, como mostrado na Fig. 1(a). Pior ainda, se a qualidade visual de um rosto falsificado for tremendamente degradada, como por exemplo, comprimido por JPEG ou H.264 com uma alta taxa de compressão, os artefatos de falsificação serão contaminados por erros de compressão e, às vezes, não poderão mais ser capturados no domínio RGB. Felizmente, esses artefatos podem ser capturados no domínio da frequência, como sugerido por muitos estudos anteriores (Yu, 2019), na forma de distribuições de frequência incomuns quando comparadas

com rostos reais. No entanto, como incorporar pistas relacionadas à frequência nos modelos de CNN de aprendizado profundo? Essa questão também surge em paralelo. Domínios de frequência convencionais, como FFT e DCT, não correspondem à invariância de deslocamento e à consistência local inerentes às imagens da natureza, portanto, estruturas de CNN tradicionais podem ser inviáveis. Como resultado, a representação de frequência compatível com CNN torna-se fundamental se quisermos aproveitar o poder de representação discriminativa de CNNs treináveis para detecção de falsificação facial com reconhecimento de frequência. Para tanto, apresentamos duas pistas de falsificação com reconhecimento de frequência que são compatíveis com a mineração de conhecimento por redes convolucionais profundas.

De um ponto de vista, é possível decompor uma imagem separando seus sinais de frequência, sendo que cada componente da imagem decomposta indica uma determinada banda de frequências. A primeira pista de falsificação sensível à frequência é, portanto, descoberta pela intuição de que somos capazes de identificar artefatos sutis de falsificação que são de certa forma salientes (ou seja, na forma de padrões incomuns) nos componentes decompostos com frequências mais altas, como os exemplos mostrados na coluna do meio da Fig. 1(b).

Essas estatísticas de frequência se recombinaem em um mapa espacial multicanal, onde o número de canais é idêntico ao número de bandas de frequência. Como mostrado na última coluna da Fig. 1(b), os rostos falsificados têm estatísticas de frequência local distintas em comparação com os rostos reais correspondentes, mesmo que pareçam quase iguais nas imagens RGB. Além disso, as estatísticas de frequência local também seguem os layouts espaciais das imagens RGB de entrada, beneficiando-se, assim, de um aprendizado de representação eficaz proporcionado por CNNs. Enquanto isso, como os componentes da imagem decomposta e as estatísticas de frequência local são complementares entre si, mas ambos compartilham uma semântica inerentemente semelhante relacionada à frequência, eles podem ser progressivamente fundidos durante o processo de aprendizado de características.



Onde Qia, 2020 propõe a Rede de Frequência em Falsificação Facial (F3-Net), A estrutura proposta é composta por dois ramos sensíveis à frequência: um visa aprender padrões sutis de falsificação por meio da Decomposição de Imagem Sensível à Frequência (FAD), e o outro busca extrair semântica de alto nível das Estatísticas de Frequência Local (LFS) para descrever a discrepância estatística sensível à frequência entre rostos reais e falsificados. Esses dois ramos são gradualmente fundidos por meio de um módulo de atenção cruzada, chamado MixBlock, que incentiva interações ricas entre os ramos FAD e LFS mencionados anteriormente. O modelo completo de detecção de falsificação facial é aprendido pela perda de entropia cruzada de forma ponta a ponta. Experimentos extensivos demonstram que a F3-Net proposta melhora significativamente o desempenho em mídias falsificadas de baixa qualidade com um estudo de ablação completo. Mostramos também que nossa estrutura supera amplamente os métodos de última geração concorrentes em todas as qualidades de compressão no desafio FaceForensics++ (Rossler ET AL, 2019). Como mostrado na Fig. 1(c), a eficácia e a superioridade da F3-Net com reconhecimento de frequência proposta são claramente demonstradas pela comparação da curva ROC com a Xception (Chollet, 2017)

Vision Transformers

A arquitetura do modelo Vision Transformer (ViT), introduzida no artigo de pesquisa (Dosovitskiy et. al, 2020), estende a arquitetura Transformer introduzida no artigo (Vaswani, 2017) para lidar efetivamente com o domínio da imagem. Desenvolvido pela equipe do Google Research Brain, o modelo ViT modifica a implementação para lidar com dados de imagem.

No modelo ViT, uma imagem de entrada é dividida em tokens visuais e patches da imagem. Esses tokens visuais são incorporados em vetores codificados de dimensão fixa, e as informações de posição de cada patch também são incorporadas e combinadas com os vetores codificados. A rede codificadora Transformer processa essa representação combinada, de forma semelhante às entradas de texto (Xie et al, 2023).

Segundo (SOUDY et al, 2023) o codificador ViT consiste em múltiplos blocos, cada um composto por normalização de camada, autoatenção multi-cabeças e componentes de perceptron multicamadas (MLP). A normalização de camada estabiliza o processo de treinamento e permite que o modelo se adapte às variações entre as imagens de treinamento. A rede de autoatenção multi-cabeças gera mapas de atenção a partir dos tokens visuais incorporados, ajudando a rede a se concentrar em regiões essenciais na imagem. Os MLPs servem como uma rede de classificação de duas camadas, e o bloco MLP final, conhecido como cabeça MLP, serve como a saída do transformador. A aplicação de softmax a essa saída fornece rótulos de classificação, como no caso da Classificação de Imagens (Mogan et al, 2019). A arquitetura de um ViT envolve o processamento sequencial de tokens visuais através dos blocos codificadores do ViT, culminando na cabeça final do MLP para classificação.

A Figura 2 mostra a arquitetura do ViT.




Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable “classification token” to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).




fig : Arquitetura de sistema para pré-processamento, detecção e previsão.

Segundo SOUDY et al. (2023), a figura acima ilustra como funciona o processamento de imagens. Na etapa de pré-processamento, extraímos quadros do vídeo, aprimoramos a qualidade de cada um, diferenciamos o fundo do primeiro plano e, por fim, alinhamos os quadros de maneira adequada. A próxima etapa é a detecção, na qual as áreas que incluem o rosto, nariz e olhos são identificadas e removidas da imagem. A detecção do rosto recortado ocorre por meio de três trajetórias diferentes: a primeira foca na detecção dos olhos, a segunda na detecção do nariz e a terceira na detecção do rosto.


CLIP

Os recentes avanços em modelos pré-treinados em larga escala, que integram capacidades de visão e linguagem, têm demonstrado notável sucesso em uma variedade de tarefas que abrangem tanto imagens quanto texto (Jia et al, 2021). A principal justificativa para a ampla adoção desses modelos reside em suas interessantes capacidades de aprendizado zero-shot e robustez a mudanças de distribuição.

Radford et al 2021, propuseram o Contrastive Language-Image Pre-training (CLIP), um modelo em larga escala que exibe um desempenho robusto de zero-shot em diversas tarefas subsequentes, incluindo classificação de imagens, reconhecimento óptico de caracteres, recuperação de texto em imagens e várias outras tarefas (Radford et al , 2021). O CLIP foi pré-treinado em um conjunto de dados em larga escala contendo 400 milhões de imagens e suas respectivas legendas de texto. O CLIP foi pré-treinado utilizando uma perda contrastiva, visando maximizar a similaridade entre as imagens e legendas de texto correspondentes em comparação com pares dissimilares. Similarmente a (Radford et al 2021), Jia et al 2021. utilizaram um conjunto de dados ruidoso em larga escala contendo um bilhão de pares imagem-texto para pré-treinar seu modelo. O modelo era composto por uma arquitetura de codificador duplo, que tinha a tarefa de alinhar as representações visuais e linguísticas dos pares imagem-texto por meio de uma perda contrastiva. Eles mostraram que um conjunto de dados suficientemente grande pode compensar seu ruído, resultando em representações de última geração mesmo com uma abordagem de aprendizado tão direta.

fonte : Radford et al 2021

Figura: Enquanto os modelos de imagem padrão treinam conjuntamente um extrator de características de imagem e um classificador linear para prever algum rótulo, o CLIP treina conjuntamente um codificador de imagem e um codificador de texto para prever os pares corretos de um lote de exemplos de treinamento (imagem, texto). No momento do teste, o codificador de texto aprendido sintetiza um classificador linear zero-shot incorporando os nomes ou descrições das classes do conjunto de dados alvo.



Modelos de visão e linguagem como CLIP Radford et al 2021 e ALIGN Jia et al 2021 oferecem capacidades interessantes de aprendizado zero-shot em diversas tarefas subsequentes no entanto, para atingir níveis de desempenho comparáveis aos modelos de última geração nessas tarefas subsequentes, esses modelos requerem ajustes adicionais em conjuntos de dados específicos da tarefa. Por exemplo, mesmo em um conjunto de dados simples como o MNIST (LeCun et al, 1998), o modelo CLIP de aprendizado zero-shot (ViT-B/16) que foi testado em (Kim et al, 2021) atingiu uma precisão de apenas 55%.

METODOLOGIA

O objetivo deste estudo é realizar um benchmark abrangente e controlado de métodos de detecção de deepfakes aplicados a um dataset específico, com foco na avaliação de desempenho, eficiência computacional e robustez em cenários adversos. Para isso, propomos uma metodologia estruturada em cinco questões de pesquisa (RQs), cada uma endereçando um aspecto-chave da capacidade de generalização, eficiência e aplicabilidade prática dos modelos de detecção.

o trabalho seguirá

RQ1: Qual paradigma de detecção alcança a melhor performance no dataset [X]?

Objetivo: Identificar o paradigma (ex: CNNs, Vision Transformers, métodos baseados em CLIP, etc.) que obtém a melhor acurácia de detecção no dataset selecionado.

Abordagem:

Avaliar modelos representativos de cada paradigma (ex: Xception, EfficientNet, ViT, CLIP).

Usar métricas padronizadas: AUC, F1-score, Accuracy, Precision e Recall.

Treinar e avaliar com validação cruzada estratificada e teste em dados nunca vistos.

Comparar desempenho com e sem fine-tuning.

RQ2: Como os métodos se comparam em termos de eficiência computacional?

Objetivo: Analisar o custo computacional de cada método em termos de:

Tempo de treinamento (por época e total)

Tempo de inferência (por amostra e lote)

Uso de memória RAM e GPU

Abordagem:

Executar todos os modelos no mesmo ambiente controlado (mesma GPU, CPU, RAM).

Registrar consumo com ferramentas como nvidia-smi, htop, PyTorch Profiler.

Calcular throughput (amostras/segundo) e latência média.

Gerar gráficos de trade-off entre acurácia e tempo/memória.

RQ3: Qual método oferece o melhor equilíbrio entre acurácia e custo computacional?

Objetivo: Identificar o ponto ótimo entre precisão e eficiência.

Abordagem:

Criar uma curva de Pareto com acurácia no eixo Y e custo computacional (ex: tempo de inferência) no eixo X.

Aplicar análise custo-benefício com base em cenários de uso (ex: detecção em tempo real vs. offline).

Definir métricas de eficiência relativa (ex: acurácia por segundo de inferência).

RQ4: Como os métodos se comportam sob condições adversas?

Objetivo: Avaliar a robustez dos modelos frente a perturbações comuns em cenários reais.

Abordagem:

Aplicar degradações sintéticas nas imagens/vídeos:

Compressão (JPEG, H.264)

Ruído gaussiano

Blur (motion, gaussiano)

Redução de resolução

Medir queda de desempenho em relação ao cenário limpo.

Calcular robustez relativa: $(AUC_degradado / AUC_limpa) \times 100\%$.

Identificar métodos mais resilientes e possíveis pontos de falha.

RQ5: Qual estratégia CLIP é mais efetiva para detecção de deepfakes?

Objetivo: Comparar diferentes formas de uso do modelo CLIP para detecção de deepfakes.

Abordagem:

Testar três estratégias:

Zero-shot: uso direto do CLIP sem treinamento.

Linear probe: congelar o backbone e treinar apenas uma camada linear.

Fine-tuning com adapter: inserir adaptadores leves (ex: LoRA, AdapterFusion).

Comparar com modelos tradicionais treinados do zero.

Avaliar desempenho, velocidade de adaptação e necessidade de dados rotulados.

SOUDY, Ahmed Hatem et al. ****Deepfake detection using convolutional vision transformers and convolutional neural networks****. ****Multimedia Tools and**

Applications**, [S. I.], p. 1-25, 8 ago. 2024. Disponível em: <https://link.springer.com/article/10.1007/s11042-024-19880-8>. Acesso em: [data].

Kim, K., Kim, Y., Cho, S., Seo, J., Nam, J., Lee, K., Kim, S., e Lee, K. (2025). DiffFace: Diffusion-based face swapping with facial guidance. *Pattern Recognition*, 163:111451.

Wang, Y. et al. (2024b). Computation-efficient deep learning for computer vision: A survey. *Cybernetics and Intelligence*, pages 1–24.

Karras, T., Laine, S., e Aila, T. (2021). A style-based generator architecture for generative adversarial networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(12):4217–4228.

Peng Gao, Shijie Geng, Renrui Zhang, Teli Ma, Rongyao Fang, Yongfeng Zhang, Hongsheng Li, and Yu Qiao. 2023. Clip-adapter: Better vision-language models with feature adapters. *International Journal of Computer Vision* (2023), 1–15.

Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. 1998. Gradientbased learning applied to document recognition. *Proc. IEEE* 86, 11 (1998), 2278– 2324.

Konwoo Kim, Michael Laskin, Igor Mordatch, and Deepak Pathak. 2021. How to adapt your large-scale vision-and-language model. (2021).

Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. 2021. Learning transferable visual models from natural language supervision. In *International conference on machine learning*. PMLR, 8748–8763.

Chao Jia, Yinfei Yang, Ye Xia, Yi-Ting Chen, Zarana Parekh, Hieu Pham, Quoc Le, Yun-Hsuan Sung, Zhen Li, and Tom Duerig. 2021. Scaling up visual and visionlanguage representation learning with noisy text supervision. In *International conference on machine learning*. PMLR, 4904–4916.

Mogan JN, Lee CP, Lim KM, Ali M, Alqahtani A (2023) Gaitcnn-vit: multi-model gait recognition with convolutional neural networks and vision transformer. *Sensors* 23(8):3809

Xie J, Hua J, Chen S, Wu P, Gao P, Sun D, Lyu Z, Lyu S, Xue X, Lu J (2023) Hypersformer: a transformer-based end-to-end hyperspectral image classification method for crop classification. *Remote Sens* 15(14):3491

Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, Kaiser Ł, Polosukhin I (2017) Attention is all you need. In: *Advances in Neural Information Processing Systems* 30 (NIPS 2017)

Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X, Unterthiner T, Dehghani M, Minderer M, Heigold G, Gelly S et al (2020) An image is worth 16x16 words: transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*

Stroebel L, Llewellyn M, Hartley T et al (2023) A systematic literature review on the effectiveness of deepfake detection techniques. *J Cyber Secur Technol* 7(2):83–113. <https://doi.org/10.1080/23742917.2023.2192888>

Tolosana R, Vera-Rodriguez R, Fierrez J et al (2020) Deepfakes and beyond: a survey of face manipulation and fake detection. *Inf Fusion* 64:131–148. <https://doi.org/10.1016/j.inffus.2020.06.014>

Yu, N., Davis, L.S., Fritz, M.: Attributing fake images to gans: Learning and analyzing gan fingerprints. In: *Proceedings of the IEEE International Conference on Computer Vision*. pp. 7556–7566 (2019)

Chollet, F.: Xception: Deep learning with depthwise separable convolutions. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 1251–1258 (2017)

Mirsky Y, Lee W (2021) The creation and detection of deepfakes: a survey. *ACM Comput Surv (CSUR)* 54(1):1–41

Masood M, Nawaz M, Malik KM et al (2023) Deepfakes generation and detection: state-of-the-art, open challenges, countermeasures, and way forward. Appl Intell 53(4):3974–4026

Wang, Y., & Yu, Y. (2023). Research on human action video generation based on GAN. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 1000-1010. <https://doi.org/10.1000/xyz123>

Nguyen HM, Derakhshani R (2020) Eyebrow recognition for identifying deepfake videos. In: 2020 international conference of the biometrics special interest group (BIOSIG). IEEE, pp 1–5
Nguyen HH, Yamagishi J, Echizen I (2019a) Capsule-forensics: Using capsule networks to detect forged images and videos. In: ICASSP 2019–2019 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, pp 2307–2311
Nguyen TT, Nguyen CM, Nguyen DT et al (2019b) Deep learning for deepfakes creation and detection. arXiv Preprint <http://arxiv.org/abs/1909.11573> 1:2
Nguyen TT, Nguyen QVH, Nguyen DT et al (2022) Deep learning for deepfakes creation and detection: a survey. Comput Vis Image Underst 223:103525

Patil K, Kale S, Dhokey J et al (2023) Deepfake detection using biological features: a survey. arXiv Preprint <http://arxiv.org/abs/2301.05819>

Cui H ,Xiao Y ,Yang Y , et al. A bioinspired in-materia analog photoelectronic reservoir computing for human action processing [J]. Nature Communications, 2025, 16 (1): 2263-2263.

Yu P, Xia Z, Fei J et al (2021) A survey on deepfake video detection. IET Biom 10(6):607–624. <https://doi.org/10.1049/bme2.12031>

Gong LY, Li XJ (2024) A contemporary survey on deepfake detection: datasets, algorithms, and challenges. Electronics 13(3):585

Gambín ÁF, Yazidi A, Vasilakos A et al (2024) Deepfakes: current and future trends. Artif Intell Rev 57(3):64

LeCun, Y. (1987). Modeles connexionistes de l'apprentissage . Ph.D. thesis, Universite de Paris VI.

SOUDY, Ahmed Hatem et al. Deepfake detection using convolutional vision transformers and convolutional neural networks. [Nome da Revista], [Local], v. [volume], n. [número], p. [páginas], 2024. DOI: [DOI]. Publicado online: 8 ago. 2024.

Rana MS, Nobl MN, Murali B et al (2022) Deepfake detection: a systematic literature review. IEEE Access. <https://doi.org/10.1109/ACCESS.2022.3154404>

Xu FJ, Wang R, Huang Y et al (2022) Countering malicious deepfakes: survey, battleground, and horizon. Int J Comput Vis. <https://doi.org/10.1007/s11263-022-01606-8>

O LIBERAL. Em nove meses, crimes com IA sobem 185% no Pará. O Liberal, 2023. Disponível em: <https://www.oliberal.com/policia/em-nove-meses-crimes-com-ia-sobem-185-no-para-1.1040402>. Acesso em: 30 out. 2025.

Wang, Z., She, Q., & Ward, T. E. (2022). Generative Adversarial Networks in Computer Vision: A Survey and Taxonomy. ACM Computing Surveys, 55(8), 1-38. <https://doi.org/10.1145/3558000>

Martin Arjovsky and Léon Bottou. 2017. Towards Principled Methods for Training Generative Adversarial Networks. arXiv:1701.04862. Retrieved from <https://arxiv.org/abs/1701.04862>.

3 Liu M ,Li W ,He B , et al. Human Action Recognition Based on 3D Convolution and Multi-Attention Transformer [J]. Applied Sciences, 2025, 15 (5): 2695-2695.

2 Cui H ,Xiao Y ,Yang Y , et al. A bioinspired in-materia analog photoelectronic reservoir computing for human action processing [J]. Nature Communications, 2025, 16 (1): 2263-2263.

Bengio, Y., Courville, A., & Vincent, P. (2013). Representation learning: A review and new perspectives. IEEE Transactions on Pattern Analysis and Machine Intelligence, 35(8), 1798-1828. <https://doi.org/10.1109/TPAMI.2013.50>

Zhou, L., Fan, Q., Huang, X., & Liu, Y. (2023). Weak and strong convergence analysis of Elman neural networks via weight decay regularization. Optimization, 72(9), 2287–2309. <https://doi.org/10.1080/02331934.2022.2057852>

Zhou, X., Wang, Y., & Wu, P. (2020). Detecting deepfake videos via frame serialization learning. Paper presented at the 2020 IEEE 3rd International Conference of Safe Production and Informatization (IICSPI).

Liu, Q., & Celebi, N. (2021). Large feature mining and deep learning in multimedia forensics. Paper presented at the Proceedings of the 2021 ACM Workshop on Security and Privacy Analytics.

Singh, P., Masud, M., Hossain, M. S., Kaur, A., Muhammad, G., & Ghoneim, A. (2021). Privacy-preserving serverless computing using federated learning for smart grids. IEEE Transactions on Industrial Informatics, 18(11), 7843–7852.

STANFORD UNIVERSITY. Convolutional Neural Networks. UFLDL Tutorial, 2015. Disponível em: <http://ufldl.stanford.edu/tutorial/supervised/ConvolutionalNeuralNetwork/>. Acesso em: 20 jan. 2024.

Tariq, S., Lee, S., & Woo, S. (2021). One detector to rule them all: Towards a general deepfake attack detection framework. Paper presented at the Proceedings of the Web Conference 2021.

Chugh, K., Gupta, P., Dhall, A., & Subramanian, R. (2020). Not made for each other-audio-visual dissonance-based deepfake detection and localization. Paper presented at the Proceedings of the 28th ACM International Conference on Multimedia. Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2015). Gated feedback recurrent neural networks. Paper presented at the International conference on machine learning.

Yazdinejad, A., Parizi, R. M., Srivastava, G., & Dehghantanha, A. (2020). Making sense of blockchain for AI deepfakes technology. Paper presented at the 2020 IEEE Globecom Workshops (GC Wkshps).

QIAN, Yuyang et al. ****Thinking in Frequency: Face Forgery Detection by Mining Frequency-aware Clues****. In: EUROPEAN CONFERENCE ON COMPUTER VISION, 16., 2020, Glasgow. ****Proceedings**** [...]. Cham: Springer, 2020. p. 1-17. (Lecture Notes in Computer Science, v. 12357).

Rossler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., Nießner, M.: Faceforensics++: Learning to detect manipulated facial images. In: Proceedings of the IEEE International Conference on Computer Vision. pp. 1–11 (2019)

KAUR, Achhardeep et al. Deepfake video detection: challenges and opportunities. Multimedia Tools and Applications, [S. l.], 29 maio 2024. Disponível em: <https://link.springer.com/article/10.1007/s11042-024-19587-w>. Acesso em: 15 out. 2024.

ESTRUTURA COMPLETA DO ARTIGO - BENCHMARK DE DETECÇÃO DE DEEPFAKES

TÍTULO

****Comparative Benchmark of Deep Learning Paradigms for Deepfake Image Detection: Traditional, Deep Learning, and Generative AI Approaches****

ou

****From Handcrafted to Generative: A Comprehensive Benchmark of Deepfake Detection Methods****